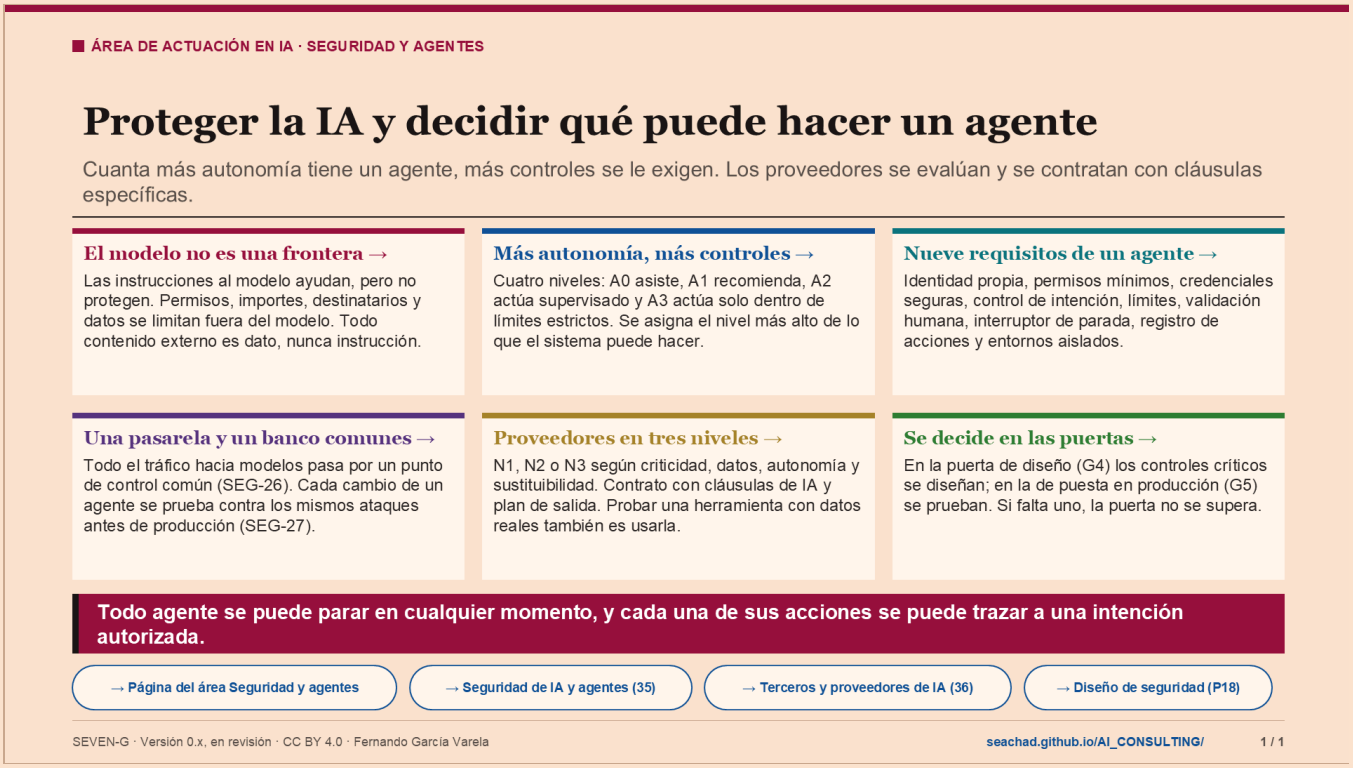


Notas

Esta slide resume el área de actuación Seguridad y agentes de SEVEN-G. Responde a tres preguntas: cómo se protege la IA, qué puede hacer un agente y con qué proveedores. Un agente es un sistema de IA que ejecuta acciones sobre otros sistemas, datos o personas mediante herramientas y permisos. Ya no solo responde: paga, escribe, comunica o cambia datos en nombre de la compañía. Por eso su seguridad es un asunto de la dirección, no solo del equipo técnico.

Los seis bloques, uno a uno:

- El modelo no es una frontera de seguridad. Las instrucciones que se dan al modelo ayudan, pero se pueden saltar. Un atacante puede esconder instrucciones en un correo, un documento o una web que el sistema lee: es la inyección de instrucciones. Por eso los límites que importan se aplican fuera del modelo.
- Más autonomía, más controles. A0 informa o resume y la persona decide. A1 propone y la persona valida cada acción. A2 actúa dentro de límites y la persona supervisa. A3 ejecuta secuencias sin revisión individual y la persona fija límites y puede pararlo. Se asigna el nivel más alto de lo que el sistema puede hacer, no el de su uso habitual. Un A3 lo decide el comité de IA en G4 y en G5.
- Nueve requisitos de un agente. Los cumple todo sistema A2 o A3 y, en lo que corresponda, A1. Destacan tres: identidad propia, distinta de la de cualquier empleado y con un responsable humano; control de intención, que comprueba fuera del modelo que cada acción encaja con lo autorizado; e interruptor de parada, que detiene el agente sin desplegar código y revoca sus credenciales.
- Una pasarela y un banco de pruebas comunes. La pasarela corporativa de IA es el punto de control por el que pasa todo el tráfico hacia modelos, con filtros, prevención de fuga, cuotas y registro. El banco de pruebas corporativo de agentes es una biblioteca versionada de ataques simulados. Sin ellos, la seguridad depende de lo que recuerde cada equipo y nadie puede decir al consejo si los controles funcionan.

- Proveedores en tres niveles. La mayor parte de la IA de una compañía depende de terceros. Cada relación se clasifica N1, N2 o N3 por el factor más exigente. El contrato asegura, entre otras cosas, que los datos de la compañía no entrenan modelos de otros. Y probar una herramienta externa con un documento real ya es usarla: la evaluación del proveedor llega antes que los datos.
- Se decide en las puertas. Un control crítico no diseñado bloquea la puerta de diseño (G4); no probado, bloquea la de puesta en producción (G5). Sobre ellos no se admite continuar con condiciones. Quien construye el agente no hace sus pruebas adversarias de G5.

Por qué importa. Un error de un asistente es una respuesta mala. Un error de un agente puede ser un pago, un mensaje a un cliente o un dato borrado. Fijar la autonomía, los límites y la parada antes de producción convierte la confianza en la IA en una regla que se aprueba, se prueba y se audita.

Pregunta para el aula: si mañana un agente de su compañía empezara a actuar de forma extraña, ¿quién podría pararlo y cuánto tardaría?

Para ir más lejos, abra la página del área, el documento 35 (seguridad de IA y agentes), el 36 (terceros y proveedores) y la plantilla de diseño de seguridad (P18).

FUENTES Y ENLACES

- **Página del área Seguridad y agentes** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/areas/seguridad.html
- **Documento 35 · Seguridad de IA y agentes** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/35_SEVEN-G_Seguridad_de_IA_y_agentes.html
- **Documento 36 · Terceros y proveedores de IA** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/36_SEVEN-G_Terceros_y_proveedores_de_IA.html
- **Glosario (documento 02) · Autonomía de sistemas y agentes** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/02_SEVEN-G_Glosario_y_convenciones.html#4-11-autonomia-de-sistemas-y-agentes
- **OWASP Top 10 para aplicaciones agénticas** https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/
- **Seguridad de IA y agentes (35)** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/35_SEVEN-G_Seguridad_de_IA_y_agentes.html
- **Terceros y proveedores de IA (36)** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/36_SEVEN-G_Terceros_y_proveedores_de_IA.html
- **Diseño de seguridad (P18)** https://seachad.github.io/AI_CONSULTING/SEVEN-G/html/es/plantillas/P18_SEVEN-G_Diseno_de_seguridad.html

AVISO LEGAL

Aviso legal: ayuda metodológica genérica y gratuita, «tal cual» y con fines informativos; no es asesoramiento jurídico ni está revisada jurídicamente para ningún caso. Cada organización la adapta y es responsable de su revisión legal y de su cumplimiento regulatorio; puede no recoger cambios normativos recientes. En la máxima medida permitida por la ley, el autor no asume responsabilidad alguna por los efectos de su aplicación. No otorga certificación de ningún tipo. Detalle en el documento 93.

CC BY 4.0 (contenidos) · MIT (código) · Fernando García Varela · seachad.github.io/AI_CONSULTING/